DOCUMENTO DE DISEÑO ARQUITECTÓNICO (HLD)

Despliegue de Producción: Plataforma de Automatización n8n e IA Corporativa sobre K3s

Fecha	Versión	Descripción
14-Oct-2026	1.0	Definición inicial arquitectura producción (4 nodos k3s + IA Centralizada)
14-Oct-2026	1.1	Inclusión de microservicios ms-gateway y ms-cron al clúster K3s

1. Objetivo y Alcance

El presente documento detalla la arquitectura de referencia, topología de red y requerimientos de infraestructura para llevar la plataforma de automatización (n8n) y su integración con modelos de Inteligencia Artificial al ambiente de **Producción**.

La solución migra de un entorno monolítico basado en Docker hacia un modelo nativo de la nube sobre **Kubernetes (K3s) multi-nodo en infraestructura local (On-Premise)**. Esto garantiza alta disponibilidad, aislamiento seguro de red, y elimina cuellos de botella mediante la distribución de bases de datos.

Dentro del alcance del clúster K3s se incluye:

- Orquestación de n8n en Modo Cola (Editor web desacoplado de workers de ejecución).
- Capa de mensajería (Redis) y persistencia transaccional (PostgreSQL).
- Servidor Vectorial Dedicado (PostgreSQL + pgvector) para múltiples iniciativas corporativas.
- **Inclusión de Gateways:** Despliegue de producción de los componentes ms-gateway y ms-cron dentro de un namespace aislado de K3s.

2. Justificación Arquitectónica

1. Uso de K3s: K3s proporciona un orquestador certificado ('baterías incluidas') que consume una fracción de memoria RAM ideal para instalaciones locales.

2. Externalización de Ollama: Mover la inferencia IA local (Ollama) fuera del clúster de n8n hacia un servicio corporativo centralizado (Granja de GPUs) evita bloqueos (OOM) en los pipelines.

3. pgvector: pgvector consolida el ecosistema en el estándar PostgreSQL, aportando gobierno de datos empresarial, RBAC y búsqueda híbrida.

4. Incorporación del Gateway a K3s: Desplegar ms-gateway en Kubernetes permite gobernar su salida mediante Network Policies perimetrales.

3. Requerimientos de Infraestructura Física / Virtual

Para la arquitectura de **4 Nodos Físicos/Virtuales** se requiere el aprovisionamiento de las siguientes máquinas bajo el segmento aislado 172.18.0.0/24:

Servidor / Hostname	Rol en Clúster	vCPU	RAM	Almacenamiento Local (PV)
SRV-K3S-MASTER (Host 1)	Master + Ingress (n8n-main, ms-cron)	4	8 GB	60 GB SSD (Sistema OS y Etcd)
SRV-K3S-WORKER-01 (Host 2)	Pool de Cómputo (n8n-workers, gateway)	8	16 GB	80 GB SSD (Contenedores efímeros)
SRV-K3S-DATA-01 (Host 3)	BD Transaccional (PostgreSQL n8n + Redis)	4	16 GB	150 GB NVMe/SSD Rápido
SRV-K3S-VECTOR-01 (Host 4)	Vector Store IA (pgvector Corporativo)	8	32 GB	200 GB NVMe Alta Vel.

Requisitos de Red Perimetral y Firewall:

- **Ingress (Entrada):** Apertura del puerto HTTPS (443) hacia el dominio de intranet.
- **Egress (Salida Externa):** Salida HTTPS restringida a la lista blanca api.openai.com.
- **Egress (Salida Interna - IA Centralizada):** Conexión TCP desde los workers hacia el Servidor Dedicado de Ollama.
- **Egress (Salida Interna - Red ADS):** Bloqueo explícito desde la subred 172.18.0.x hacia la intranet, permitiendo **únicamente** tráfico desde ms-gateway.

4. Diagrama de Arquitectura de Producción

Topología lógica con K3s aislando los flujos de automatización (n8n-system), el estado de los datos (data-state) y la pasarela de control hacia los sistemas core (gateway-dmz).

